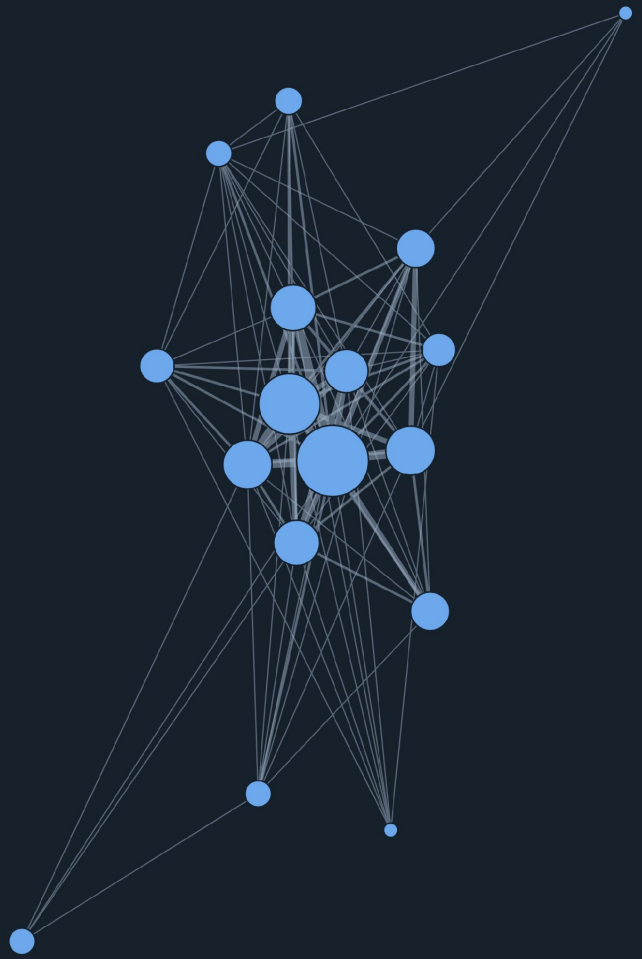


Do texto à rede

Co-ocorrência de entidades nomeadas

Algoritmos e Estrutura de Dados II · Grafos

ivanovitch.silva@ufrn.br
@ivanovitchm

UFRN
UNIVERSIDADE FEDERAL DO RIO GRANDE DO NORTE

DCA

Três jeitos de construir uma rede. Hoje entra o quarto.



arquivo

CSV com uma aresta por linha



à mão

nó por nó, aresta por aresta



Internet

coleta por snowball na Wikipédia



texto

a fonte mais abundante de todas

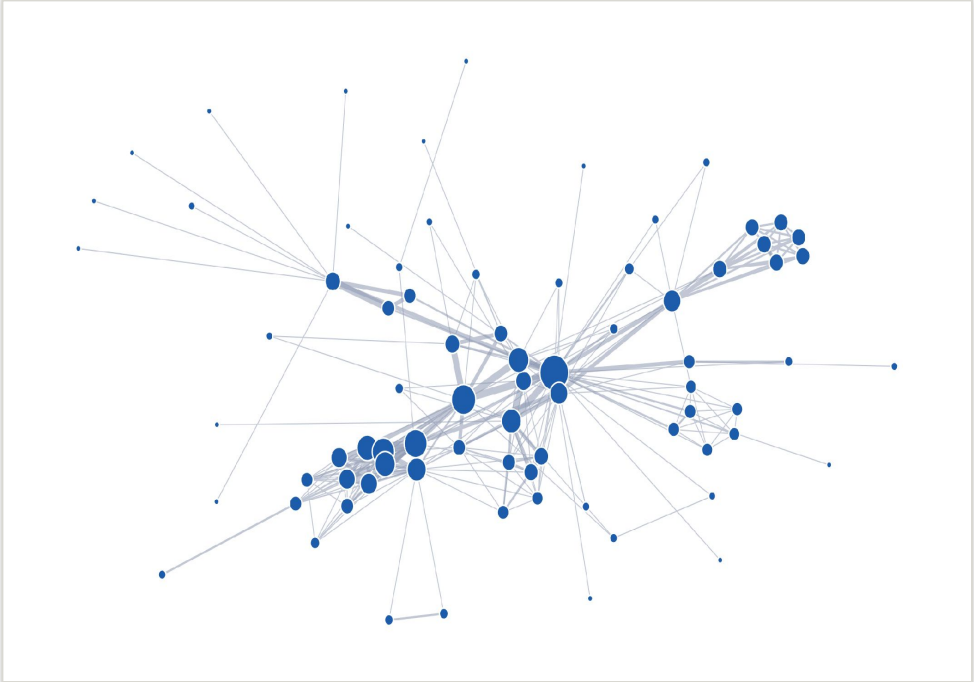
Um texto não tem nós nem arestas explícitos. Ele tem palavras. A ponte entre palavras e grafo é uma ideia de uma linha.

1993. Donald Knuth lê Os Miseráveis com lápis na mão.

Capítulo a capítulo, ele anota quais personagens aparecem juntos. O resultado vira a rede que hoje vem embutida no NetworkX.

Nesta aula fazemos o trabalho de Knuth em segundos, em português, com um romance que a turma inteira já ouviu falar.

```
import networkx as nx
g = nx.les_miserables_graph()
# 77 personagens, 254 arestas
# peso = capítulos compartilhados
```



Quem aparece com quem, quantas vezes, e que estrutura isso forma?

Donald E. Knuth. The Stanford GraphBase: A Platform for Combinatorial Computing, 1993.

A ideia inteira cabe em uma linha

Duas coisas estão na mesma unidade de texto $\Longrightarrow$ existe uma aresta entre elas.

fatiar

o que é uma unidade?

capítulo, parágrafo, sentença, documento, janela de w sentenças

extrair

o que é um item?

pessoas, lugares, organizações, palavras-chave, hashtags

ligar

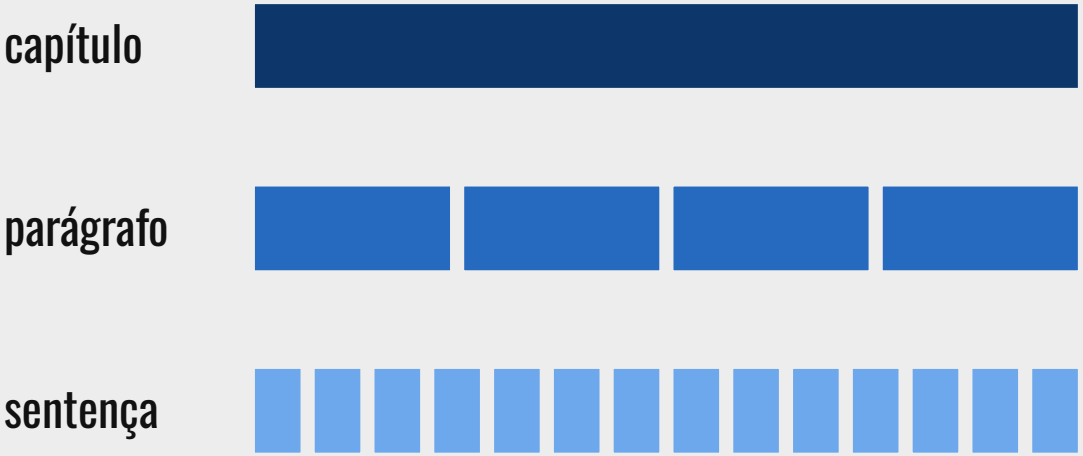
o que é estar junto?

contagem, presença, Jaccard, PMI (pointwise mutual information)

Três decisões de modelagem. Cada uma muda a rede resultante. O NER entra só no segundo verbo, como ferramenta.

Fatiar. A janela define o que é uma unidade

O mesmo texto, três fatiamentos. Nada muda nas palavras; muda o conjunto U.



Janela grande

redes densas, cliques grandes, a informação migra para os pesos.

Janela pequena

redes esparsas, estrutura visível, relações expressas em frases separadas se perdem.

Pare e pense *Se a unidade fosse o texto inteiro, tudo co-ocorreria com tudo. Que rede é essa?*

Extrair. Itens são entidades nomeadas

Trechos do texto que nomeiam algo do mundo, cada um com um rótulo de tipo.

pessoa

`PER`

Capitu, José Dias

lugar

`LOC`

Rua do Ouvidor, Japão

organização

`ORG`

Gazeta de Notícias

outro

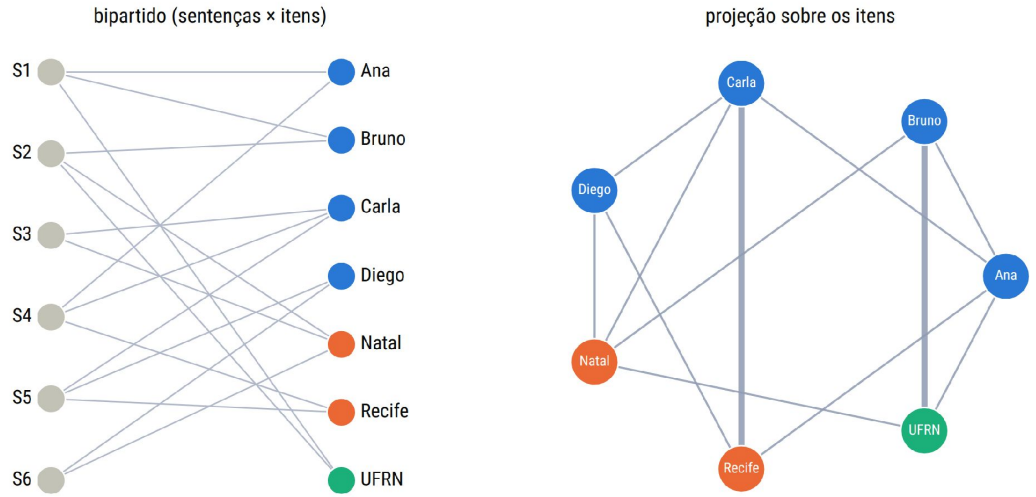
`MISC`

Hamlet, Eclesiastes

S1 **Ana** e **Bruno** estudam na **UFRN**. S4 **Ana** viajou para **Recife** com **Carla**.

Caixa de ferramentas Marcar esses trechos à mão funciona para seis frases, não para 148 capítulos. A ferramenta emprestada do PLN faz isso por nós, atrás de uma única função. Daqui a poucos slides.

Ligar. A rede de co-ocorrência é uma projeção



Bipartido

unidades de um lado, itens do outro, uma aresta por ocorrência.

Projeção sobre os itens

dois itens são vizinhos se dividem uma unidade; o peso conta as unidades divididas.

$$w(i, j) = |N(i) \cap N(j)|$$

Gestalt em ação Continuidade. Cada aresta da projeção é um caminho de comprimento 2 no bipartido, item → sentença → item. A largura conta esses caminhos.

A mesma coisa em matrizes

B é a matriz de incidência (unidades × itens). C = $B^{T}B$ conta co-ocorrências.

B	Ana	Bruno	Carla	Diego	Natal	Recife	UFRN
S1	1	1	0	0	0	0	1
S2	0	1	0	0	1	0	1
S3	0	0	1	0	1	0	0
S4	1	0	1	0	0	1	0
S5	0	0	1	1	0	1	0
S6	0	0	0	1	1	0	0

C	Ana	Bruno	Carla	Diego	Natal	Recife	UFRN
Ana	**2**	1	1	0	0	1	1
Bruno	1	**2**	0	0	1	0	2
Carla	1	0	**3**	1	1	2	0
Diego	0	0	1	**2**	1	1	0
Natal	0	1	1	1	**3**	0	1
Recife	1	0	2	1	0	**2**	0
UFRN	1	2	0	0	1	0	**2**

Diagonal unidades em que o item aparece (frequência documental).

Fora da diagonal unidades compartilhadas, o peso da aresta.

Gestalt em ação Continuidade. No bipartido inteiro, A^2 tem $B^{T}B$ como bloco. Contar co-ocorrências é contar passeios de comprimento 2, a mesma ideia da aula de passeios.

O artefato do clique

Uma unidade com k itens gera k(k−1)/2 arestas de uma vez.

20 itens → 190 arestas	40 itens → 780 arestas	50 itens → 1.225 arestas

Custo

construir a projeção custa $O(\Sigma k^2)$, dominado pelas unidades grandes.

Estrutura

uma unidade grande vira um clique e infla densidade, clustering e k-core. É o problema dos artigos com centenas de autores da aula de k-core.

Remédio, normalizar pela frequência dos dois itens. `J(i, j) = C_ij / (C_ii + C_jj - C_ij)`

O que a co-ocorrência não é

> “Diego nunca esteve em Natal.”

Essa frase liga Diego a Natal com a mesma força que “Diego mora em Natal”. A rede não lê negações, não sabe quem falou com quem, não distingue amigo de inimigo.

Ela mede uma coisa só, e mede bem. **Atenção compartilhada dentro de uma unidade de texto.**

Pare e pense *Guarde este exemplo. Ele reaparece toda vez que alguém disser que uma aresta “significa relacionamento”.*

A ferramenta. Reconhecimento de entidades nomeadas

Caixa de ferramentas Única parte da aula que fala de PLN. Tudo que está dentro do modelo fica fechado na caixa. Para nós basta o contrato.

O que faz

recebe texto e devolve os trechos que nomeiam algo do mundo, com um rótulo PER, LOC, ORG ou MISC.

Como faz, em uma frase

um modelo estatístico treinado em textos anotados por humanos aprende pistas como inicial maiúscula, palavras vizinhas e nomes já vistos.

```
def extrair_entidades(texto):
    doc = nlp(texto)
    return DataFrame(
        mencao, tipo,
        inicio, fim, sentenca)

# contrato: texto -> tabela de menções
# spaCy, modelo pt_core_news_md
```

De volta ao grafo Se amanhã a ferramenta for outra (modelo maior, lista de nomes, API), só esta função muda. O resto é grafo.

Três limitações, todas nossas para resolver



Erra por excesso

Palavras em maiúscula no começo da frase viram entidade.

`Vamos · Vi · Juro`



Confunde tipos

O modelo pequeno rotula Capitu como lugar em 227 de 334 vezes. Pádua, que também é uma cidade, sai como lugar até no modelo médio.

`Capitu → LOC`



Não resolve identidade

Quatro formas, uma pessoa. Juntá-las é decisão de modelagem, não da ferramenta.

`Bentinho · Bento · Santiago · Dom Casmurro`

Os trechos costumam vir certos e os tipos nem sempre. A rede depende dos trechos, não dos tipos. Identidade não vem da ferramenta.

O pipeline inteiro. O NER é um produtor de tabelas

Artefatos em cartões brancos, operações em azul. A única operação que não é grafo, em cinza.



texto → unidades → menções → nós → rede

Caixa de ferramentas Extrair é o único passo que pertence ao PLN. Ele recebe unidades de texto e devolve uma tabela de menções. Todo o resto é modelagem de grafos.

De volta ao grafo Resolver é a etapa nova entre extrair e ligar. Transforma menções em nós, e é modelagem de grafos, não pré-processamento.

Estudo de caso 1. Dom Casmurro

Quem aparece com quem. 1899, narrado em primeira pessoa por Bento Santiago, o Bentinho. A unidade é o capítulo.

148	1.575	2.099	716	17	93
capítulos	parágrafos	menções (NER)	formas distintas	nós	arestas

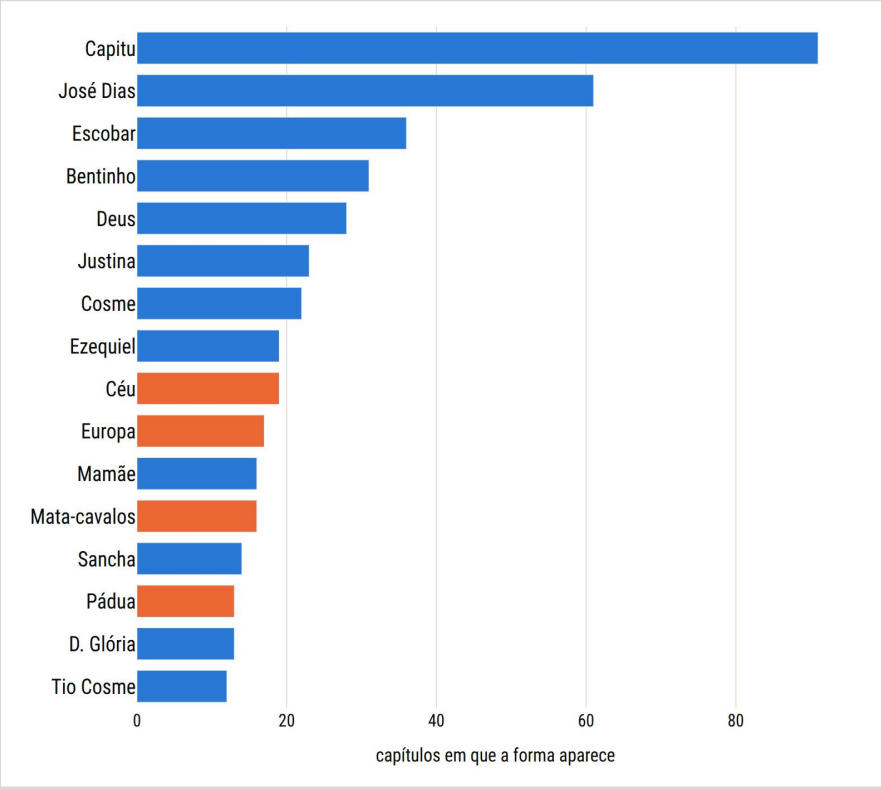
Fatiar 148 capítulos marcados por CAPÍTULO N; quebras de linha normalizadas, porque José\nDias não é José Dias.

Extrair nlp.pipe em lote, dez segundos. Cada menção guarda três identificadores de unidade, capítulo, parágrafo e sentença.

Resolver dicionário de aliases mais peneira automática.

Ligar projeção ponderada por capítulo.

Olhar a lista suja antes de limpar



Ruído de início de frase

Vamos, Vi, Fui, Juro viram entidade. Todos aparecem em minúscula em outro lugar do texto; Capitu nunca. É o teste da minúscula.

Tipo errado

Pádua (o pai de Capitu) sai como lugar na maioria das vezes. Para a rede tanto faz; para a legenda, corrigimos com conhecimento do texto.

Identidade partida

D. Glória, Mamãe, mamãe e Dona Glória são a mesma pessoa. Nenhum algoritmo cego resolve com segurança; quem leu o livro resolve em dois minutos.

cor = tipo majoritário dado pela ferramenta · 16 formas mais frequentes, em capítulos

Resolver. De menções a nós, em duas passagens

1 · Dicionário de aliases

escrito por quem conhece o texto; tem prioridade absoluta.

```
ALIASES = {
  "Bentinho":  ["Bento", "Santiago",
                "Dom Casmurro"],
  "D. Glória": ["Mamãe", "Dona Glória"],
  "Tio Cosme": ["Cosme", "Mano Cosme"],
  ...            # 16 personagens
}
```

2 · Peneira automática

para o que sobrou, quatro critérios.

- tipo majoritário PER
- em pelo menos 3 capítulos
- passa no teste da minúscula
- tem forma de nome próprio (maiúsculas ligadas por de, da, e)



peneira · 4 (Desdêmona)

Destino das 2.099 menções. Não existe pipeline de texto sem uma lista como a da esquerda; o que existe é pipeline que a esconde.

Projeção e contração não comutam

Resolver aliases depois de projetar soma arestas e conta o mesmo capítulo duas vezes.

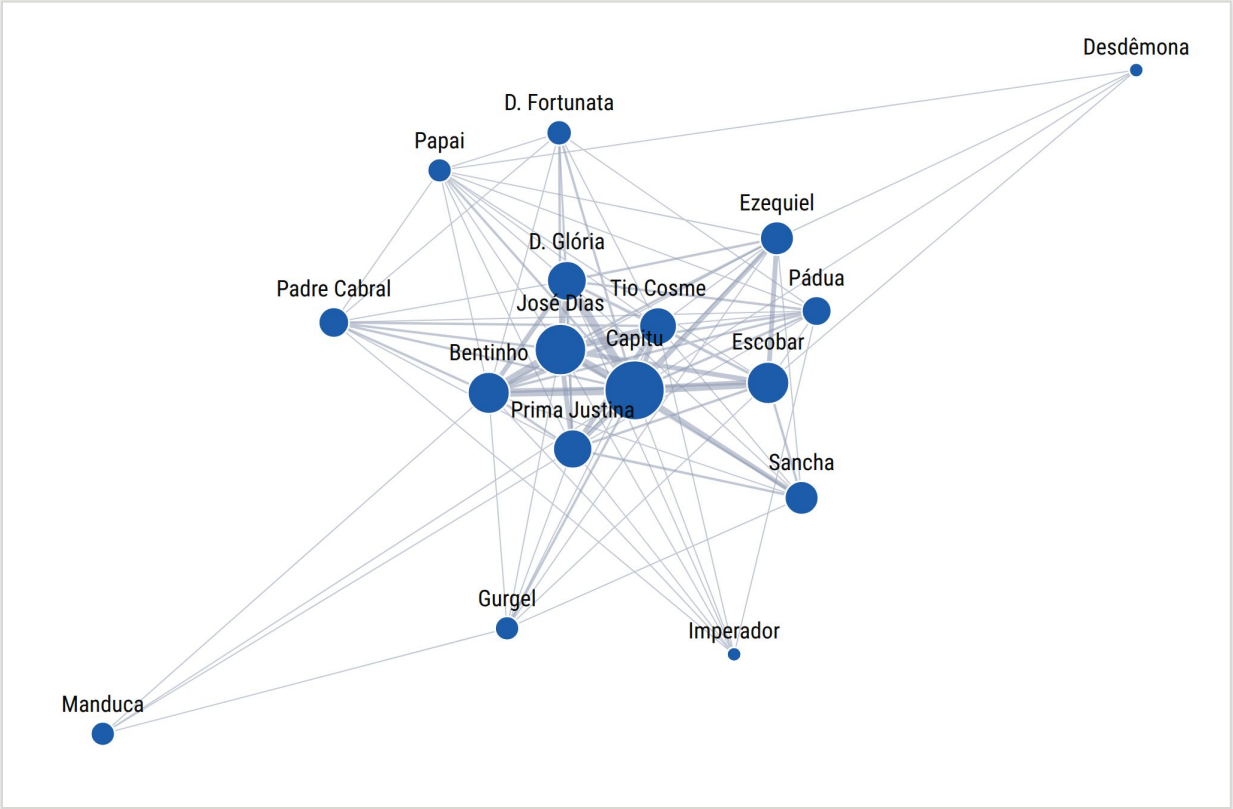
par	contração (soma)	tabela (correto)
Capitu · D. Glória	37	24
José Dias · Tio Cosme	40	22
Capitu · Bentinho	32	29
Capitu · José Dias	43	40

Se Mamãe e D. Glória aparecem no mesmo capítulo que Capitu, a rede por formas tem duas arestas contando aquele capítulo.

A contração soma as duas. Resolver na tabela, antes de projetar, conta o capítulo uma vez.

O que fica Resolver identidade é modelagem, e deve acontecer na tabela de menções, antes da projeção.

A rede de personagens, por capítulo

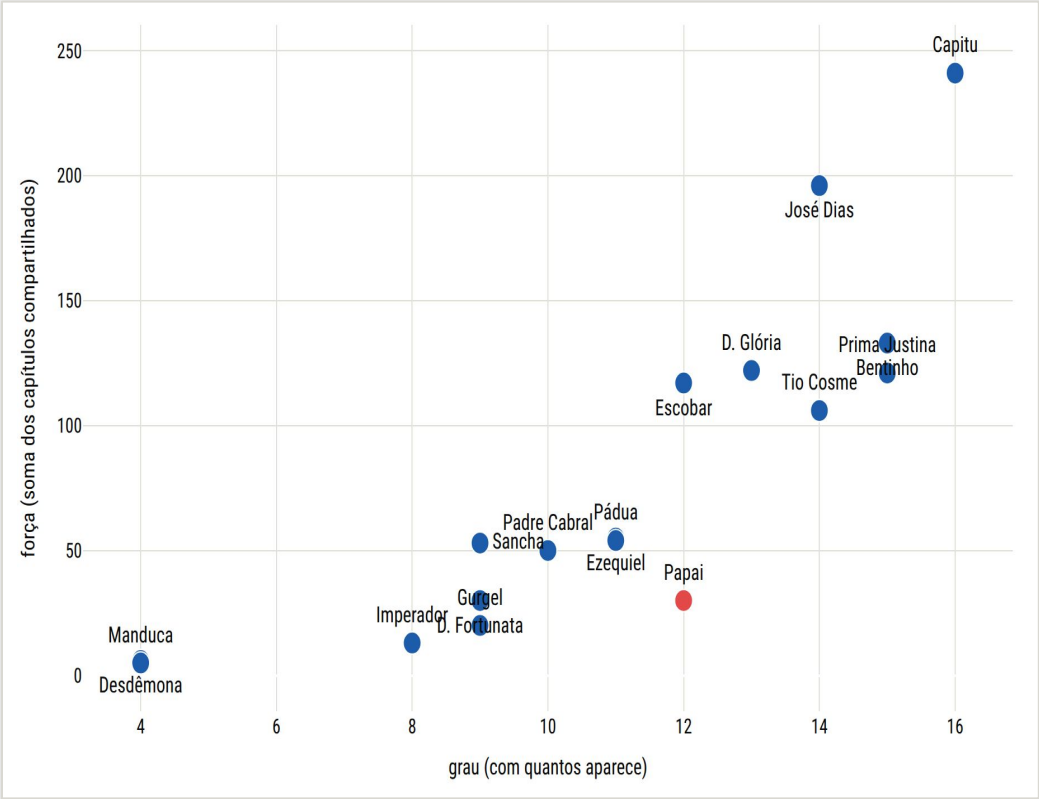


As arestas mais pesadas

40 Capitu · José Dias
32 Capitu · Escobar
29 Bentinho · Capitu
26 Bentinho · José Dias
24 Capitu · D. Glória
23 D. Glória · José Dias

tamanho = capítulos em que aparece
largura = capítulos compartilhados
layout usa o peso

Ler a rede. Grau saturou, força não



Grau saturou

densidade 0,68; oito dos 17 personagens têm grau 12 ou mais. A força vai de 241 a 5. Em co-ocorrência, força é a medida de primeira leitura.

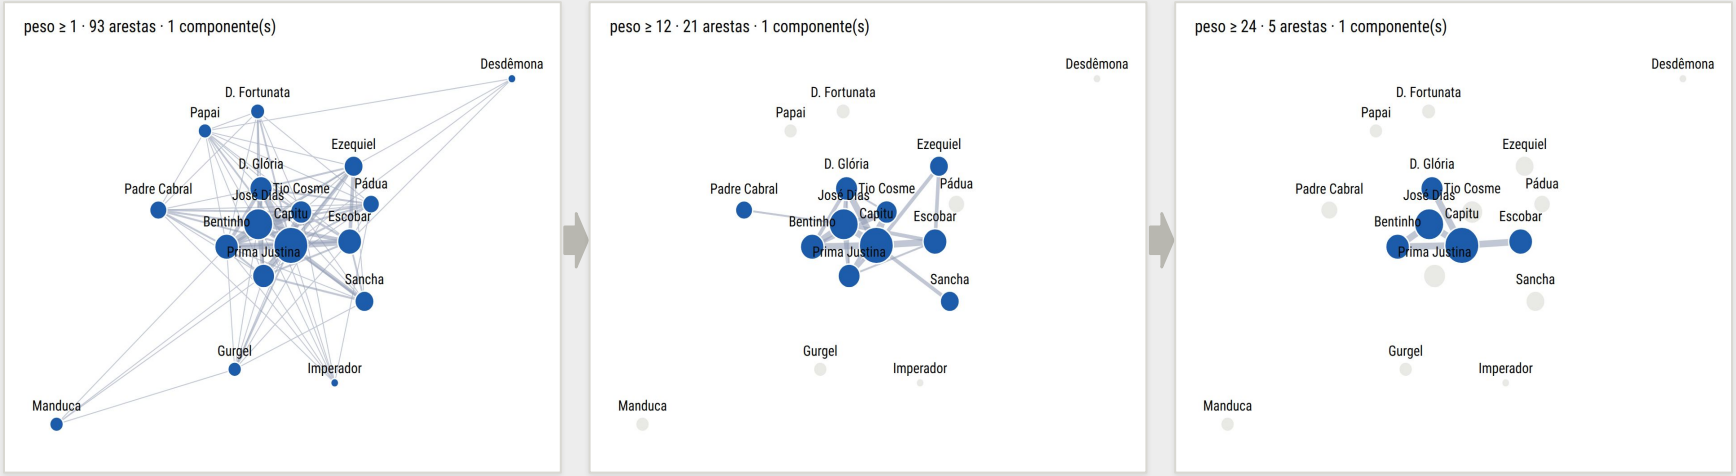
Capitu concentra a intermediação

ponderada por 1/peso. As arestas mais pesadas são as dela; quase todo caminho leve passa por ela.

Bentinho é um nó fantasma

narrador em primeira pessoa, presente em 148 capítulos, nomeado em 35. A ferramenta conta nomes, não presenças.

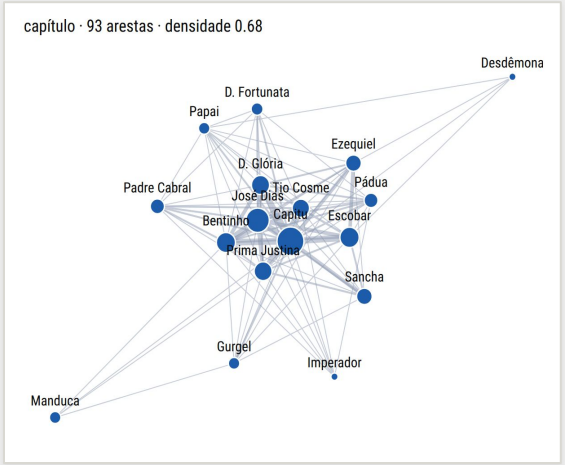
O esqueleto. Subindo o limiar de peso

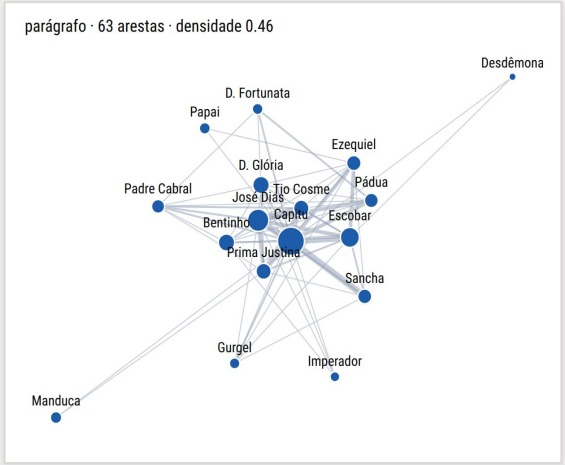


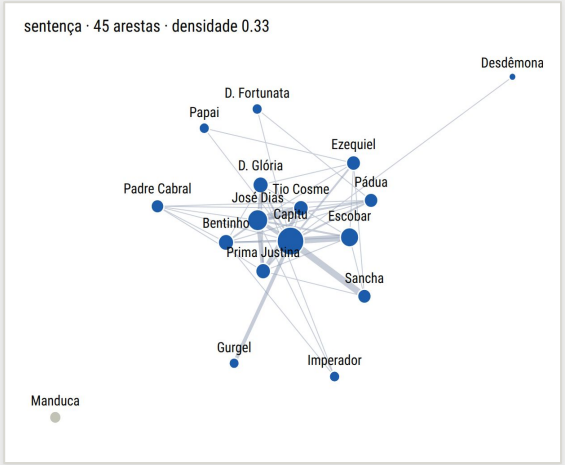
Gestalt em ação Destino comum. Arestas de mesmo peso somem juntas; nós que perdem todas as arestas apagam. Posições fixas nos três quadros para que o olho compare estrutura, não layout.

Pare e pense *Capitu · Escobar compartilha 32 capítulos e sobrevive até o fim. A rede não julga ninguém, ela conta. Mas conta o que o romance passa 148 capítulos insinuando.*

A janela muda a rede. Mesmas menções, três recortes







janela	arestas	densidade	clustering	componentes
capítulo	93	0,68	0,86	1
parágrafo	63	0,46	0,8	1
sentença	45	0,33	0,58	2

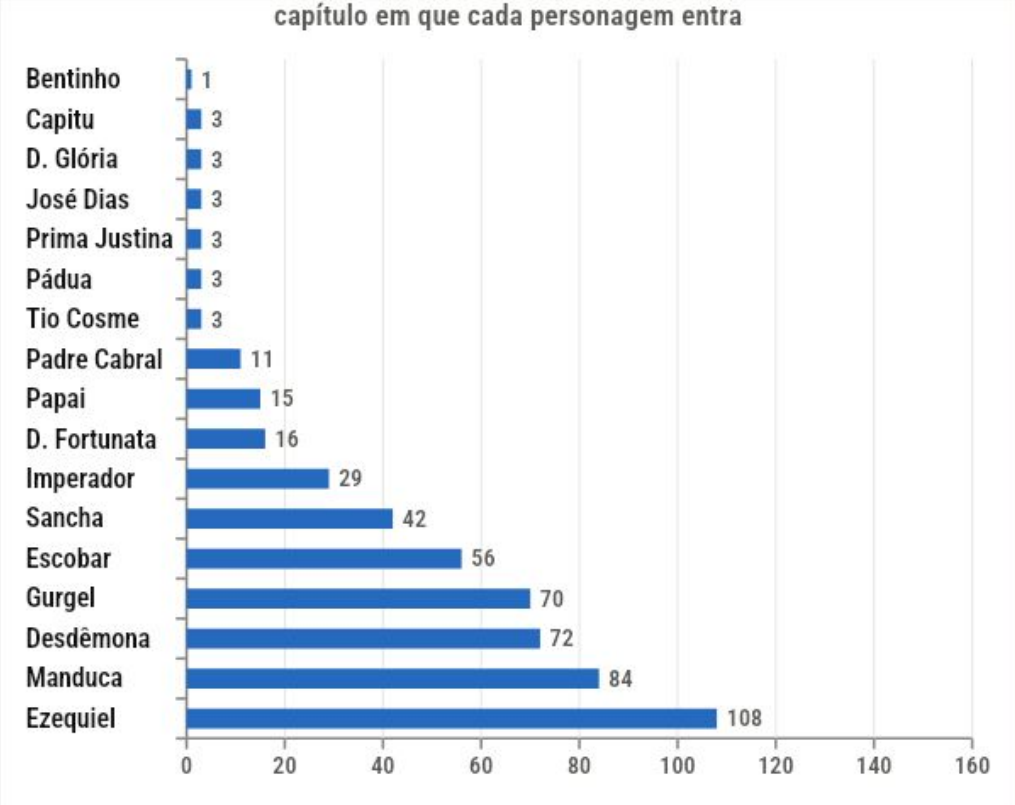
Aresta mais pesada

por capítulo, Capitu · José Dias, com folga.

por sentença, empate triplo entre José Dias · Tio Cosme, Capitu · Sancha e Capitu · Escobar.

A janela não muda só a topologia. Muda quem parece mais próximo de quem.

As ausências contam a cronologia do romance



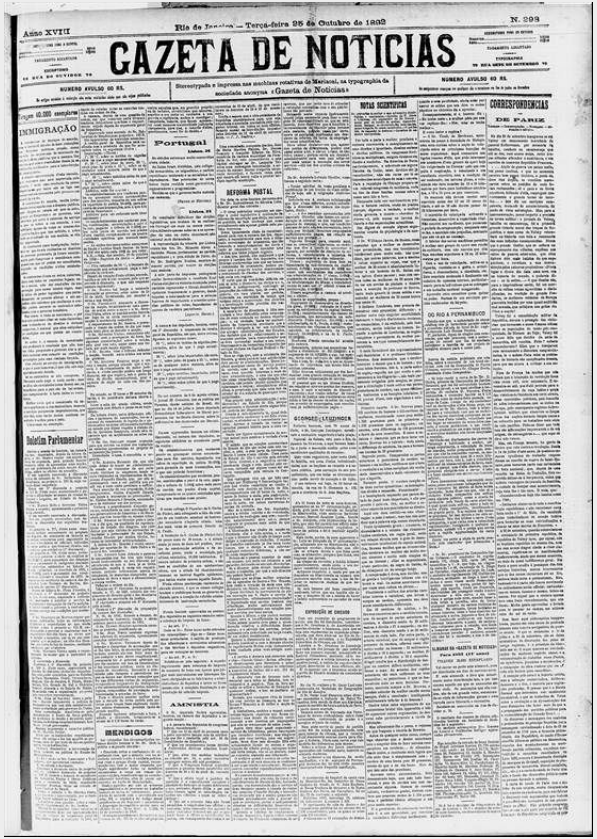
Pares frequentes que nunca dividem um capítulo

- Ezequiel · Pádua
- Ezequiel · Padre Cabral
- Sancha · Papai
- Escobar · Padre Cabral
- Manduca · quase todo mundo

Ezequiel, o filho, nasce quando Pádua, Padre Cabral e D. Fortunata já saíram de cena. Sancha nunca cruza com o círculo da infância. A foto estática já sugere o filme por trás.

Uma não aresta numa rede densa é tão informativa quanto uma aresta numa rede esparsa!!!

Estudo de caso 2. Coluna "A Semana", na *Gazeta de Notícias*


Anno XVIII — Rio de Janeiro — Terça-feira 25 de Outubro de 1892 — N. 299

GAZETA DE NOTICIAS

NUMERO AVULSO 60 RS.

Dirigida, redigida e impressa nas machinas rotativas de Marinoni, na typographia da sociedade anonyma «Gazeta de Noticias»

NUMERO AVULSO 60 RS.

NOTAS SCIENTIFICAS

CORRESPONDENCIAS

DE PARIS

IMMIGRAÇÃO

Portugal

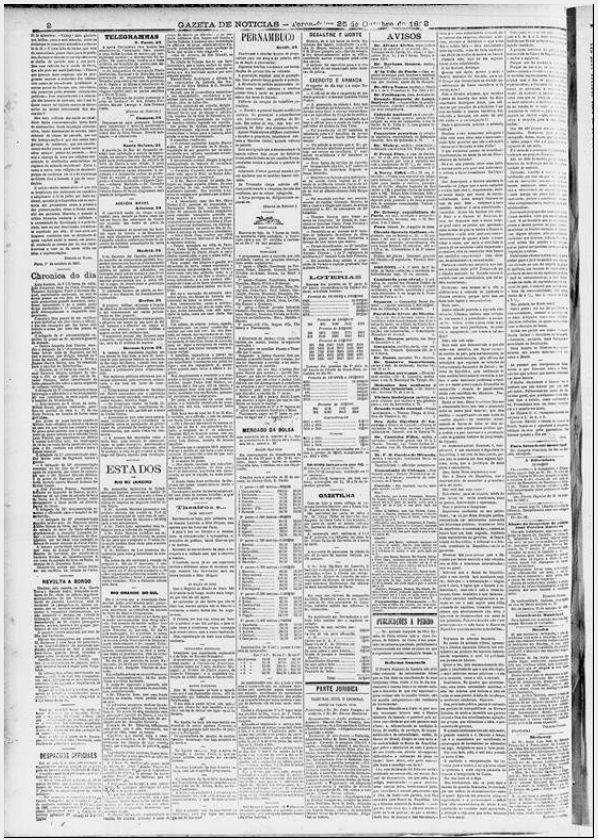
REFORMA POSTAL

Boletim Parlamentar

GEORGES LEYGUES

AMNISTIA

BENDEGÓ


GAZETA DE NOTICIAS — Terça-feira 25 de Outubro de 1892

TELEGRAMMAS

PERNAMBUCO

DESASTRE E MORTE

AVISOS

Chronica do dia

ESTADOS

GAZETILHA

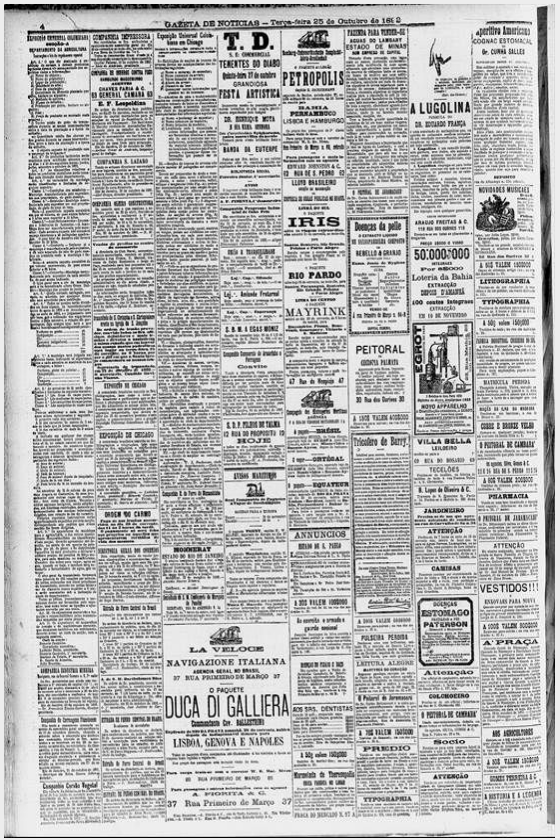
LOTERIAS

MERCADO DA BOLSA

REVISTA A BORDO

DESPACHOS TELEGRAPHICOS

PARTE JUDICIAL


GAZETA DE NOTICIAS — Terça-feira 25 de Outubro de 1892

T. D.

TENENTES DO DIABO

PETROPOLIS

IRIS

RIO BARDO

MAYRINK

PEITORAL

LA VELOCE

NAVIGAZIONE ITALIANA

DUCA DI GALLIERA

LISBOA, GENOVA E NAPOLES

ANNUNCIOS

A LUGOLINA

50:000$000

Lotería da Bahia

VESTIDOS!!!

Estudo de caso 2. A Semana, o mundo real em 244 crônicas

Coluna semanal de Machado na Gazeta de Notícias, 1892 a 1897. A unidade agora é o documento.

244	1,5 M	7.837	3.564	304	6.072
crônicas	caracteres	menções (NER)	formas distintas	nós aprovados	arestas

Unidade = documento

crônicas têm tamanhos muito diferentes, e tamanho vira estrutura falsa.

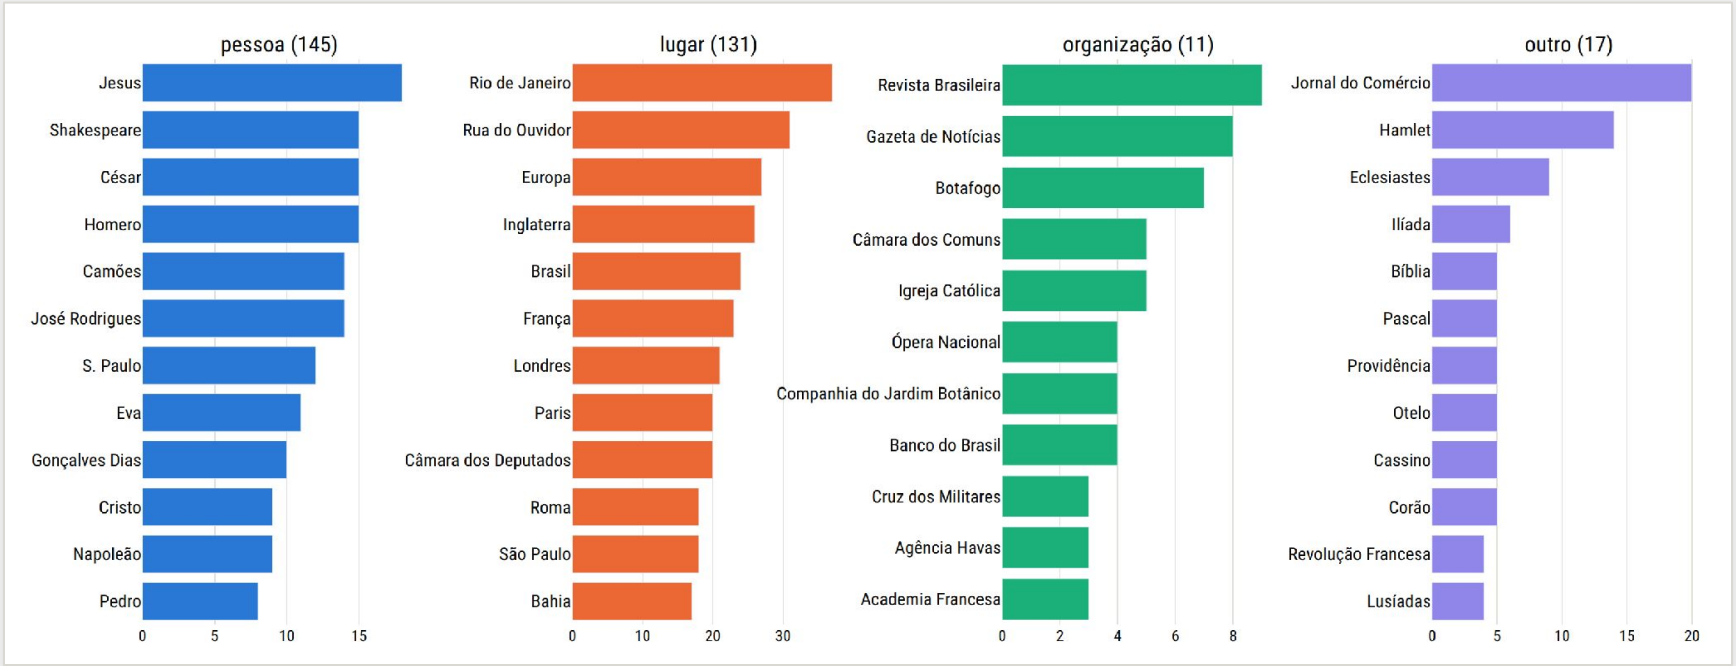
Itens com tipos

pessoas, lugares, organizações e obras na mesma rede.

Uma data por unidade

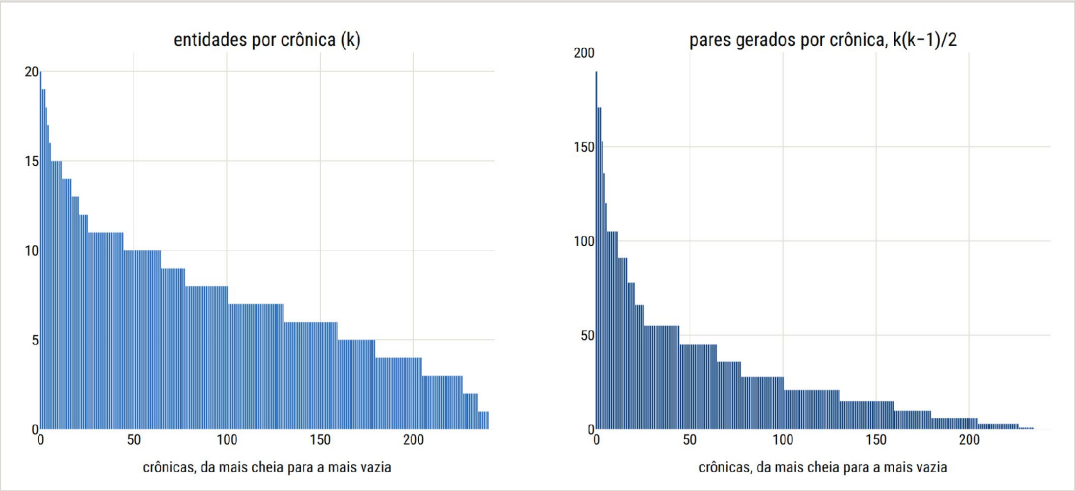
a rede pode ser vista mudando no tempo.

Dois mundos na mesma coluna. O noticiário e a biblioteca



As entidades mais frequentes por tipo (em crônicas). Rio de Janeiro, Inglaterra e Câmara dos Deputados de um lado; Homero, Shakespeare e Hamlet do outro.

O artefato do clique, ao vivo



20 entidades na crônica mais cheia

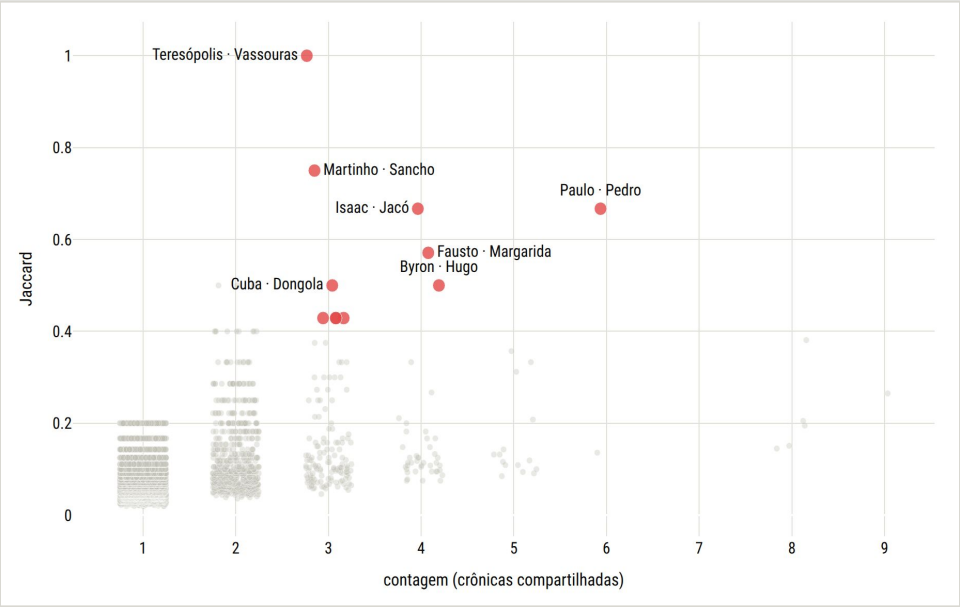
35% dos pares vêm de 10% das crônicas

25 degenerescência da projeção

Cada crônica com 20 entidades vira um K_{20} na projeção. Cliques de crônicas diferentes, sobrepostos em alguns nós (Rio de Janeiro, Europa, Inglaterra), formam um núcleo denso onde o k-core não mede coesão, **mede tamanho de documento.**

O que fica É a mesma armadilha dos artigos com centenas de autores da aula de k-core, e a mesma resposta serve. Olhar os pesos e normalizar.

Contagem ou Jaccard? Cada peso responde a uma pergunta

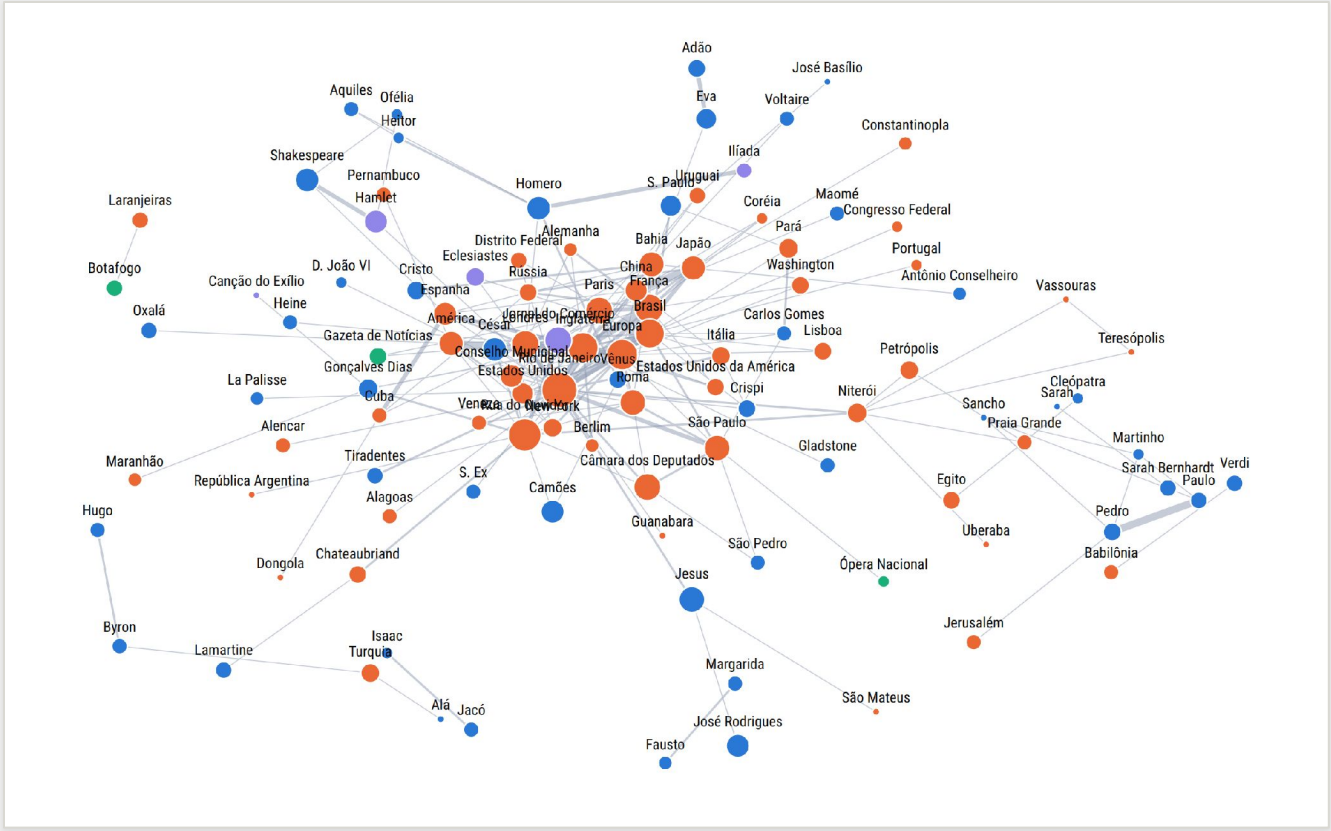


top por contagem	cont.	Jacc.
América · Europa	9	0,265
China · Japão	8	0,381
Brasil · Rio de Janeiro	8	0,151
Inglaterra · Londres	8	0,205
França · Inglaterra	8	0,195

top por Jaccard (cont. ≥ 3)	cont.	Jacc.
Teresópolis · Vassouras	3	1
Martinho · Sancho	3	0,75
Isaac · Jacó	4	0,667
Paulo · Pedro	6	0,667
Fausto · Margarida	4	0,571

Gestalt em ação Figura e fundo. A nuvem cinza é a maioria das arestas. Em vermelho, os pares que aparecem quase só juntos. Contagem devolve hubs; Jaccard devolve pares exclusivos e denuncia aliases não resolvidos (Sarah · Sarah Bernhardt).

O esqueleto, agora com tipos (peso ≥ 3)



- pessoa
- lugar
- organização
- outro

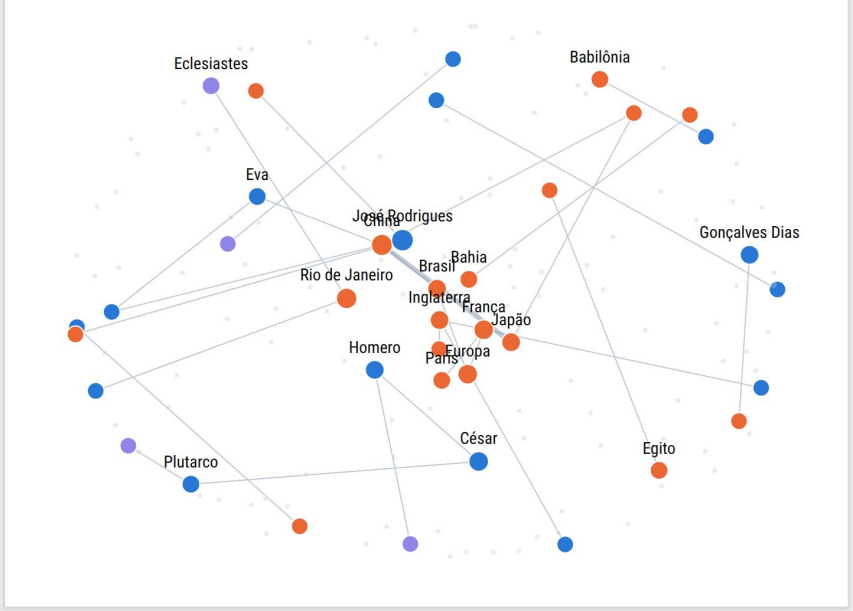
108 nós
200 arestas
9 componentes

Os lugares (laranja) formam a espinha dorsal do componente grande; as pessoas (azul) se penduram nele.

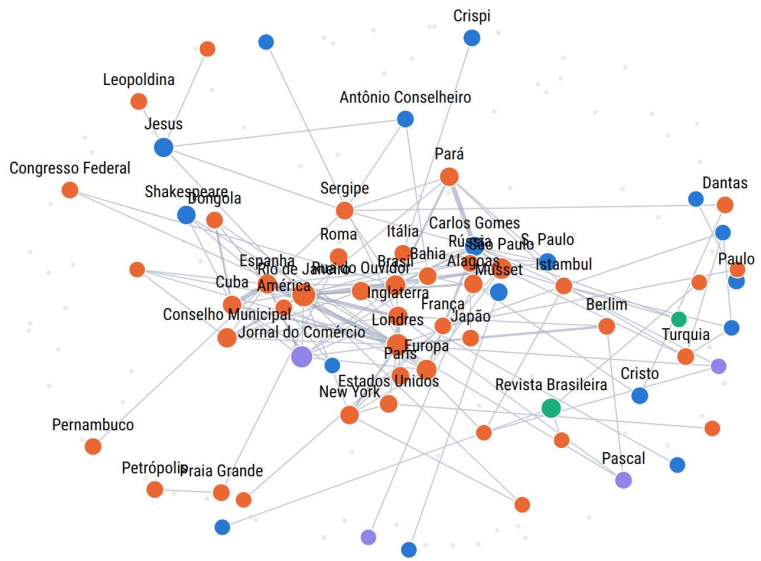
Os pares soltos na periferia são os exclusivos do Jaccard. Fausto · Margarida, Isaac · Jacó, Botafogo · Laranjeiras.

A rede no tempo. Cada ano coloca coisas diferentes juntas

1894 · 52 crônicas · mais fortes: China, Japão, Inglaterra, Adão, Eva

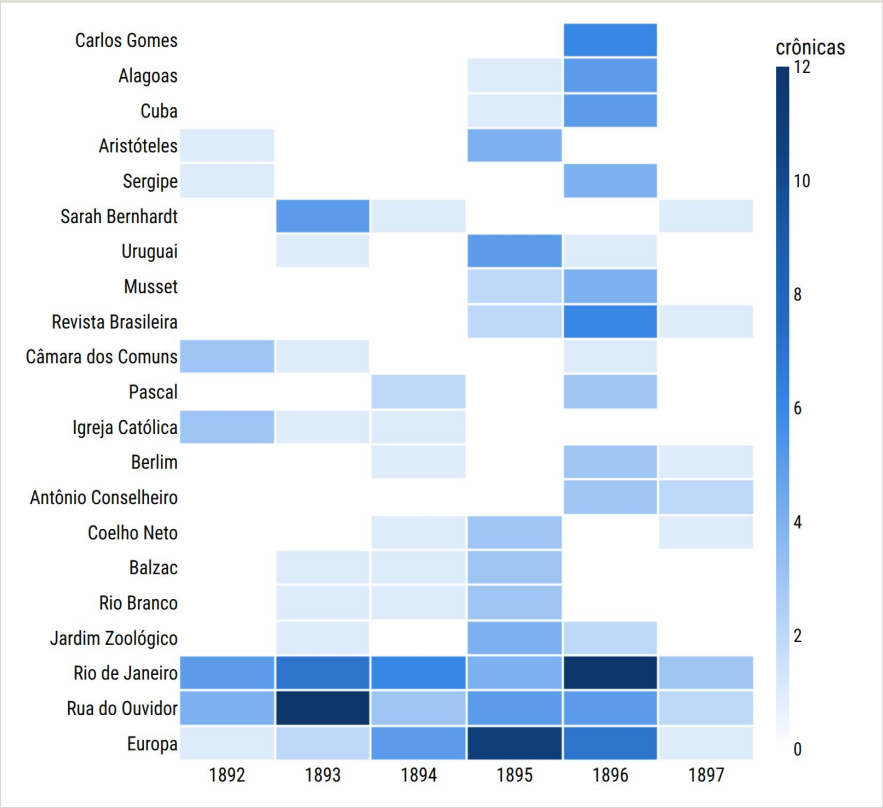


1896 · 51 crônicas · mais fortes: Londres, Rio de Janeiro, Espanha, Carlos Gomes, Inglaterra



Gestalt em ação Destino comum. Mesmas posições nos dois quadros; os nós do ano acendem com a cor do tipo, os ausentes ficam cinza. 1894 acende China e Japão (a guerra sino-japonesa). 1896 acende Antônio Conselheiro (Canudos), ligado a Bahia e Sergipe.

Barômetro do noticiário



Linhas são entidades; colunas, anos; a cor é o número de crônicas do ano em que a entidade aparece, em uma única matiz azul.

Uma mancha escura isolada é um assunto de um ano só (Carlos Gomes em 1896, Sarah Bernhardt em 1893, Antônio Conselheiro em 1896 e 1897). Uma linha uniforme é um assunto permanente (Rio de Janeiro, Rua do Ouvidor).

O que fica Datas transformam a foto em filme, e o filme é um barômetro do que o texto estava colocando junto em cada época.

Desafios. Três resolvidos, três abertos

#	desafio	estado	dificuldade
1	B^TB com matrizes esparsas	**resolvido**	★☆☆
2	Janelas de w sentenças, a curva inteira	**resolvido**	★★☆
3	Troque a ferramenta, mantenha a rede	**resolvido**	★★☆
4	A rede no tempo do romance	**aberto**	★★★
5	Outro romance, outro narrador	**aberto**	★★★
6	Wikipédia ao vivo, e os links como resolução de identidade	**aberto**	★★★★

Resolvido leia o enunciado, tente antes de abrir a solução, depois compare. **Aberto** critérios de aceitação e pistas; alguns tocam em pesquisa em aberto. Entregue como notebook separado.

O que fica

É uma projeção

de um bipartido unidades × itens; o peso conta unidades compartilhadas. $C = B^{\top}B$.

A janela decide

densidade, clustering, componentes e até qual par parece mais próximo.

Resolver é modelagem

identidade se resolve na tabela, antes de projetar. Projeção e contração não comutam.

Força, não grau

em elencos pequenos o grau satura; a leitura passa pela força e pelo esqueleto por limiar.

O artefato do clique

documentos grandes inflam a projeção; contagem revela hubs, Jaccard revela pares exclusivos.

NER é ferramenta

uma função com contrato. Os trechos importam, os tipos são atributos, identidade não vem dela.

Referências e material

- Knuth, D. E. (1993). The Stanford GraphBase. ACM Press. A rede de Os Miseráveis, feita à mão.
- Newman, M. (2018). Networks, 2ª ed. Oxford University Press. Redes bipartidas e projeções.
- Coscia, M. (2021). The Atlas for the Aspiring Network Scientist. networkatlas.eu.
- Elson, Dames e McKeown (2010). Extracting social networks from literary fiction. ACL.
- Labatut, V. e Bost, X. (2019). Extraction and analysis of fictional character networks: a survey. ACM Computing Surveys.
- Moretti, F. (2011). Network theory, plot analysis. New Left Review, 68.
- Nadeau, D. e Sekine, S. (2007). A survey of named entity recognition and classification. Lingvisticae Investigationes.
- Serrano, Boguñá e Vespignani (2009). Extracting the multiscale backbone of complex weighted networks. PNAS.
- Honnibal, Montani et al. (2020). spaCy. spacy.io · Bird, Klein e Loper (2009). NLTK, corpus machado (domínio público).

De volta ao grafo Notebook da aula, ner_coocorrencia.ipynb, no repositório github.com/ivanovitchm/datastructure. Roda no Colab, sem depender de sites externos.